

Mejoramiento de la capacidad de generalización para la detección de retinopatía diabética mediante módulos de atención de bloque convolucional

Improving the generalizability of diabetic retinopathy detection using convolutional block attention modules

Juan Bocaranda², Luis Lasso², Angie Navas², Jesús Solís², Roberto Villarreal², Juan Castillo¹

¹ Facultad de Ingeniería Industrial, Universidad Tecnológica de Panamá, Panamá

² Facultad de Ingeniería de Sistemas Computacionales, Universidad Tecnológica de Panamá, Panamá

*Autor de correspondencia: juan.castillo21@utp.ac.pa

RESUMEN. El presente estudio extiende una investigación previa sobre la capacidad de generalización de modelos basados en redes neuronales convolucionales para la detección y clasificación de retinopatía diabética, incorporando el módulo de atención Convolutional Block Attention Module (CBAM) sobre la arquitectura ResNet50. La investigación evalúa el impacto de este mecanismo de atención en escenarios de evaluación intra-dominio y cruzada entre dominios, con el propósito de analizar su contribución a la robustez e interpretabilidad de modelos aplicados al análisis de imágenes de retina. Los resultados evidencian que la incorporación de CBAM no produjo mejoras consistentes en la capacidad de generalización del modelo respecto a la arquitectura base. Si bien se observaron beneficios en escenarios específicos, el desempeño global mostró que los mecanismos de atención no garantizan una mejora automática cuando se aplican a conjuntos de datos con características heterogéneas. Asimismo, el análisis de interpretabilidad permitió identificar diferencias en los patrones de activación de ambas arquitecturas según el dominio evaluado. El estudio se desarrolló utilizando los datasets públicos APTOS 2019, Messidor y Ocular Disease Intelligent Recognition (ODIR), los cuales presentan diferencias en tamaño, distribución de clases, dispositivos de captura y características demográficas de los pacientes. Estas variaciones representan una limitación inherente para la evaluación de la generalización entre dominios y constituyen un desafío para la transferencia de modelos a contextos clínicos diversos. La retinopatía diabética es una de las principales causas de pérdida de visión prevenible a nivel mundial. En este contexto, la principal contribución de esta investigación radica en proporcionar evidencia experimental sobre las condiciones bajo las cuales los mecanismos de atención pueden mejorar o no la capacidad de generalización, robustez e interpretabilidad de modelos de inteligencia artificial aplicados al análisis de imágenes médicas.

Palabras clave. *Generalización, Imágenes médicas, Módulos de atención de bloque convolucional, Retinopatía diabética.*

ABSTRACT. This study extends previous research on the generalizability of convolutional neural network-based models for the detection and classification of diabetic retinopathy by incorporating the Convolutional Block Attention Module (CBAM) on the ResNet50 architecture. The research evaluates the impact of this attentional mechanism in intra-domain and cross-domain assessment scenarios, aiming to analyze its contribution to the robustness and interpretability of models applied to retinal image analysis. The results show that incorporating CBAM did not produce consistent improvements in the model's generalizability compared to the base architecture. While benefits were observed in specific scenarios, overall performance demonstrated that attentional mechanisms do not guarantee automatic improvement when applied to heterogeneous datasets. Furthermore, the

Citación: J. Bocaranda, L. Lasso, A. Navas, J. Solís, R. Villarreal y J. Castillo, "Mejoramiento de la capacidad de generalización para la detección de retinopatía diabética mediante módulos de atención de bloque convolucional", *Revista de I+D Tecnológico*, vol. 21, no. 1, pp. (0), 2026.

Tipo de artículo: No_modificar. **Recibido:** No_modificar. **Recibido con correcciones:** No_modificar. **Aceptado:** No_modificar.

DOI.

Copyright: 2026 J. Bocaranda, L. Lasso, A. Navas, J. Solís, R. Villarreal y J. Castillo. This is an open access article under the CC BY-NC-SA 4.0 license (<https://creativecommons.org/licenses/by-nc-sa/4.0/>).

interpretability analysis identified differences in the activation patterns of both architectures depending on the domain being assessed. The study was conducted using the public datasets APTOS 2019, Messidor, and Ocular Disease Intelligent Recognition (ODIR), which differ in size, class distribution, capture devices, and patient demographics. These variations represent an inherent limitation for evaluating cross-domain generalizability and pose a challenge for transferring models to diverse clinical contexts. Diabetic retinopathy is a leading cause of preventable vision loss worldwide. In this context, the main contribution of this research lies in providing experimental evidence on the conditions under which care mechanisms may or may not improve the generalizability, robustness, and interpretability of artificial intelligence models applied to medical image analysis.

Keywords. *Generalization, Medical imaging, Convolutional Block Attention Module, Diabetic retinopathy.*

1. Introducción

La diabetes mellitus representa uno de los principales desafíos de salud pública a nivel mundial debido a su creciente prevalencia y a las complicaciones asociadas que afectan la calidad de vida de los pacientes [4], [5]. Entre estas complicaciones, las alteraciones oculares constituyen una de las principales causas de discapacidad visual prevenible en la población adulta [6]. Debido a que las manifestaciones iniciales suelen pasar desapercibidas, la detección temprana y el monitoreo continuo son fundamentales para reducir el riesgo de deterioro visual permanente [7], [8].

En respuesta a esta problemática, la inteligencia artificial ha demostrado ser una herramienta prometedora para apoyar el diagnóstico médico mediante el análisis automatizado de imágenes de retina [16], [20]. Particularmente, las redes neuronales convolucionales han obtenido resultados destacados en la identificación de patrones visuales asociados a enfermedades oculares [10], [15], [19]. Sin embargo, numerosos estudios han evidenciado que estos modelos pueden presentar dificultades para mantener un rendimiento consistente cuando son aplicados a imágenes provenientes de conjuntos de datos distintos a aquellos utilizados durante el entrenamiento [22], [25], [26].

Considerando esta situación, el presente trabajo amplía una investigación previa sobre la capacidad de generalización de modelos para clasificar imágenes de retina. Se incorpora el módulo de atención Convolutional Block Attention Module (CBAM) a una arquitectura ResNet50 con el fin de evaluar su efecto en escenarios intra-dominio y entre dominios [34]. CBAM combina mecanismos de atención espacial y de canal para resaltar características relevantes durante el aprendizaje [35], [36]. Así, se analiza si estos mecanismos favorecen la robustez, transferibilidad e interpretabilidad en la detección automática de retinopatía diabética [37], [39], [40].

2. Marco Teórico

2.1 Retinopatía diabética: Definición, evolución y clasificación

La retinopatía diabética es una enfermedad ocular de origen microvascular que se desarrolla como consecuencia de las alteraciones producidas por la diabetes mellitus sobre los vasos sanguíneos de la retina [4]. Estas alteraciones afectan el suministro adecuado de oxígeno y nutrientes a los tejidos retinianos, favoreciendo la aparición de lesiones como microaneurismas, hemorragias y exudados [4], [6]. Su progresión está relacionada con factores como la duración de la diabetes y el control glucémico del paciente [4].

Desde el punto de vista clínico, la enfermedad presenta una evolución gradual que puede avanzar desde lesiones leves hasta formas severas capaces de comprometer significativamente la función visual. Con el objetivo de estandarizar su diagnóstico y seguimiento, se han desarrollado sistemas internacionales de clasificación como la International Clinical Diabetic Retinopathy Severity Scale, la cual divide la enfermedad en cinco categorías:

- a. Sin retinopatía diabética
- b. Retinopatía diabética leve
- c. Retinopatía diabética moderada
- d. Retinopatía diabética severa
- e. Retinopatía diabética proliferativa

Esta clasificación facilita la evaluación clínica y la comparación de resultados entre diferentes estudios e instituciones [4].

La comprensión de la evolución y clasificación de la retinopatía diabética resulta fundamental para el desarrollo de herramientas automatizadas de diagnóstico. Debido a que cada nivel de severidad presenta manifestaciones visuales específicas, los sistemas basados en inteligencia artificial deben identificar características asociadas a cada categoría clínica. Por esta razón, el conocimiento de la enfermedad constituye un elemento esencial para el entrenamiento y evaluación de modelos de aprendizaje profundo aplicados al análisis de imágenes de fondo de ojo [7], [8].

2.2 Redes neuronales convolucionales

Dentro de las diferentes arquitecturas de aprendizaje profundo se encuentran las redes neuronales convolucionales (CNN), también conocidas como ConvNet [11]. Estas utilizan una arquitectura de tipo feed-forward basada en detectores

jerárquicos de características, lo que les permite aprender patrones visuales de forma eficiente [11], [12]. Entre sus principales ventajas destacan la compartición de pesos, la reducción de parámetros y una mejor capacidad de generalización respecto a redes totalmente conectadas [11].

Debido a estas propiedades, las CNN se han convertido en una de las arquitecturas más utilizadas para tareas de clasificación y análisis de imágenes [11]. Su aplicación se extiende a campos como detección de objetos, reconocimiento facial, reconocimiento de voz y diagnóstico asistido por computadora [11], [14]. En particular, han demostrado resultados prometedores en la detección y clasificación de retinopatía diabética a partir de imágenes de fondo de ojo [10], [15], [16].

2.3 Módulos de atención de bloque convolucional (CBAM)

Los mecanismos de atención constituyen una estrategia utilizada en aprendizaje profundo para mejorar la capacidad de los modelos de enfocarse en la información más relevante presente en los datos de entrada [34]. Su principio consiste en asignar diferentes niveles de importancia a determinadas características o regiones de una imagen. En aplicaciones de visión por computadora e imágenes médicas, estos mecanismos han demostrado mejorar la representación de características y la interpretación de los resultados [39], [40].

Entre los mecanismos de atención más utilizados se encuentra el Convolutional Block Attention Module (CBAM), propuesto por Woo et al. [34]. Este módulo combina atención de canal y atención espacial de manera secuencial para fortalecer la representación de características. La atención de canal identifica los mapas más relevantes para la clasificación, mientras que la atención espacial determina las regiones de la imagen que requieren mayor énfasis durante el aprendizaje [34], [38]. Esta combinación permite mejorar la capacidad de representación sin incrementar significativamente la complejidad computacional.

Diversos estudios han explorado la incorporación de módulos CBAM en arquitecturas convolucionales para mejorar la representación de características y la interpretabilidad de modelos aplicados a imágenes médicas [35], [36], [37]. En el contexto de la retinopatía diabética, estos mecanismos tienen el potencial de resaltar lesiones y estructuras retinianas relevantes para el diagnóstico. Por esta razón, la presente investigación incorpora CBAM sobre una arquitectura ResNet50 para analizar su efecto sobre el desempeño, la capacidad de generalización y la interpretabilidad de los modelos evaluados.

3. Materiales y Métodos

3.1 Diseño metodológico y experimental

El estudio se desarrolló bajo un enfoque cuantitativo orientado a evaluar el desempeño de modelos de aprendizaje profundo para la detección de retinopatía diabética a partir de

imágenes de fondo de ojo. El análisis se centró en la capacidad de generalización de una arquitectura ResNet50 y su variante con módulos de atención de bloque convolucional (CBAM), considerando diferentes conjuntos de datos y escenarios de evaluación cruzada. Para ello, se emplearon métricas objetivas de clasificación que permitieron comparar el comportamiento de los modelos bajo distintas condiciones experimentales.

Desde el punto de vista metodológico, el trabajo corresponde a una investigación de tipo experimental y comparativa. Se considera experimental porque se realizaron pruebas controladas modificando factores como el dataset de entrenamiento, el dataset de prueba, la arquitectura utilizada y la semilla experimental. Asimismo, es comparativa debido a que se analizaron los resultados obtenidos por ResNet50 Base y ResNet50 + CBAM en múltiples escenarios de evaluación [16], [24], [27].

El diseño experimental implementado corresponde a un esquema multifactorial compuesto por tres datasets de entrenamiento, tres datasets de prueba, dos arquitecturas y tres semillas experimentales. Este enfoque permite analizar el efecto individual y combinado de cada factor, así como evaluar la estabilidad y transferibilidad de los modelos cuando son aplicados a imágenes provenientes de diferentes dominios. De esta manera, se busca determinar el impacto de la incorporación de CBAM sobre el desempeño, la capacidad de generalización y la interpretabilidad de los modelos evaluados [22], [23].

3.2 Fuente de datos

Para evaluar la capacidad de generalización de los modelos propuestos se emplearon múltiples conjuntos de imágenes de fondo de ojo provenientes de diferentes fuentes. El uso de datasets heterogéneos permite analizar el comportamiento de las arquitecturas frente a variaciones en las condiciones de captura, características de los pacientes, dispositivos utilizados y distribución de clases. Esta diversidad resulta fundamental para aproximar escenarios más cercanos a la práctica clínica real.

Los experimentos se realizaron utilizando los datasets APTOS 2019, Messidor y ODIR. APTOS 2019 contiene 3662 imágenes etiquetadas según cinco niveles de severidad de retinopatía diabética [1]. Messidor incluye 1744 imágenes obtenidas en el Hospital Universitario de Brest, Francia, mediante una cámara de fondo de ojo no midriática [2]. Por su parte, ODIR recopila información de aproximadamente 5000 pacientes provenientes de hospitales y centros médicos de China, incorporando una alta variabilidad en las condiciones de adquisición de las imágenes [3].

La combinación de estos tres conjuntos de datos proporciona un entorno adecuado para evaluar la generalización en escenarios intra-dominio y cruzados entre dominios. Además, permite analizar el efecto de las diferencias existentes entre poblaciones, dispositivos y condiciones de captura sobre el desempeño de las arquitecturas estudiadas. En consecuencia, los datasets seleccionados constituyen una base representativa

para evaluar el impacto de los mecanismos de atención sobre la robustez, transferibilidad e interpretabilidad de los modelos propuestos.

3.3 Preprocesamiento y preparación de los datos

El preprocesamiento de los datos constituyó una etapa fundamental para garantizar la consistencia de la información utilizada durante el entrenamiento y evaluación de los modelos. Debido a que los datasets APTOS 2019, Messidor y ODIR provienen de diferentes fuentes y presentan variaciones en resolución, calidad de imagen y estructura de las etiquetas, fue necesario aplicar un conjunto de procedimientos orientados a homogenizar las características de entrada [22], [33]. Esta etapa permitió establecer condiciones comparables entre los conjuntos de datos y facilitar la evaluación de la capacidad de generalización en escenarios intra-dominio y cruzados entre dominios.

Como parte de este proceso, las imágenes fueron redimensionadas a una resolución uniforme de 224×224 píxeles y normalizadas para garantizar su compatibilidad con la arquitectura ResNet50. Asimismo, se unificó la escala de clasificación utilizada por los diferentes datasets para mantener correspondencia con los cinco niveles de severidad de retinopatía diabética definidos en el estudio. Adicionalmente, el dataset ODIR fue transformado desde una estructura basada en pacientes hacia una representación a nivel de imagen individual por ojo, conservando únicamente aquellos registros cuyos diagnósticos podían asociarse de manera consistente con las categorías de severidad utilizadas en la investigación.

Posteriormente, se aplicaron técnicas de aumento de datos (*data augmentation*) con el objetivo de incrementar la variabilidad de las muestras disponibles para el entrenamiento y reducir el riesgo de sobreajuste. Entre las transformaciones implementadas se incluyen la normalización de color mediante CLAHE (*Contrast Limited Adaptive Histogram Equalization*), rotaciones de 90° , 180° y 270° , volteos horizontales y verticales, así como ajustes de brillo y contraste. Estas operaciones permiten generar nuevas variaciones de una misma imagen sin alterar su contenido clínico, favoreciendo el aprendizaje de características más robustas y reduciendo la dependencia de patrones específicos de un único conjunto de datos [25], [26], [29].

La Figura 1 muestra un ejemplo del proceso de preprocesamiento y aumento de datos aplicado a las imágenes de retina antes del entrenamiento de los modelos. En ella se presenta la imagen original, seguida de una versión procesada mediante CLAHE para mejorar el contraste y resaltar estructuras relevantes como vasos sanguíneos y posibles lesiones asociadas a la enfermedad. Asimismo, se ilustran las transformaciones geométricas y fotométricas utilizadas durante el entrenamiento, las cuales permiten simular diferentes condiciones de adquisición presentes en los datasets empleados y aumentar el número efectivo de muestras disponibles para el aprendizaje [22], [23], [28].




Figura 1. Técnicas de preprocesamiento y data augmentation en imágenes de retina.

Finalmente, se aplicó una estrategia de división estratificada para construir conjuntos balanceados de entrenamiento, validación y prueba, preservando la distribución de clases en cada dataset. Adicionalmente, se incorporó una ponderación mediante *class weights* dentro de la función de pérdida para mitigar el efecto del desbalance entre categorías de severidad. En conjunto, estas etapas de preparación permitieron establecer condiciones experimentales homogéneas y garantizar una evaluación más objetiva del desempeño, la capacidad de generalización y la interpretabilidad de las arquitecturas analizadas [16], [24], [27].

3.4 Arquitecturas evaluadas

Con el propósito de analizar el efecto de los mecanismos de atención sobre la capacidad de generalización, durante el estudio se evaluaron dos arquitecturas de aprendizaje profundo: ResNet50 Base y una variante mejorada mediante la incorporación del módulo de atención Convolutional Block Attention Module (CBAM). Ambas arquitecturas fueron implementadas utilizando pesos preentrenados sobre ImageNet y recibieron como entrada imágenes de retina de 224×224 píxeles con tres canales de color (RGB). El objetivo consistió en comparar el desempeño, la generalización y la interpretabilidad de ambos modelos en escenarios de evaluación intra-dominio y cruzados entre dominios, utilizando los datasets APTOS 2019, Messidor y ODIR.

La arquitectura ResNet50, propuesta por He et al. [10], está formada por múltiples bloques residuales conectados mediante *skip connections*, las cuales permiten entrenar redes profundas mitigando el problema de degradación del rendimiento. Sea $H(x)$ la función objetivo que se desea aproximar para una entrada x . En una red convencional, la salida se expresa como:

$$H(x) = y \quad (1)$$

ResNet reformula este problema definiendo una función residual:

$$F(x) = H(x) - x \quad (2)$$

Despejando la función objetivo, se obtiene:

$$H(x) = F(x) + x \quad (3)$$

y considerando los parámetros entrenables de las capas convolucionales, la salida del bloque residual puede expresarse como:

$$y = F(x, \{W_i\}) + x \quad (4)$$

donde x representa la entrada del bloque residual, $F(x, \{W_i\})$ corresponde a la transformación aprendida por las capas convolucionales y y representa la salida del bloque. Esta formulación facilita la propagación del gradiente y permite preservar información relevante a lo largo de las capas profundas. La arquitectura se organiza mediante bloques tipo *bottleneck*, compuestos por convoluciones de 1×1 y 3×3 , seguidos de una operación de *Global Average Pooling* y una capa de clasificación con función Softmax de cinco salidas, correspondientes a los niveles de severidad de la retinopatía diabética.

Sobre la arquitectura ResNet50 se implementó una segunda variante mediante la incorporación del módulo de atención CBAM, propuesto por Woo et al. [34]. Este mecanismo fue insertado en los bloques residuales de las etapas 2, 3 y 4 de la red, operando después de las capas convolucionales y antes de la conexión residual. CBAM aplica atención de canal y atención espacial de forma secuencial. La atención de canal permite identificar qué mapas de características contienen más información discriminativa, mientras que la atención espacial resalta las regiones de la imagen con mayor relevancia para la clasificación [35], [36], [38]. La incorporación del módulo añadió aproximadamente 0.4 millones de parámetros adicionales sobre los 25.5 millones del modelo base, representando un incremento cercano al 1.6 % en el costo computacional. Los pesos de CBAM fueron inicializados mediante Xavier Uniform, mientras que los pesos preentrenados de ResNet50 se conservaron sin modificación.

Finalmente, ambas arquitecturas fueron entrenadas bajo las mismas condiciones experimentales utilizando PyTorch. Para la variante ResNet50 + CBAM se implementó una estrategia de entrenamiento en dos fases, compuesta por una etapa de calentamiento (*warm-up*) donde se entrenaron únicamente los módulos CBAM y la capa de clasificación, seguida de una etapa de *fine tuning* con toda la red. Adicionalmente, se empleó la técnica Grad-CAM para analizar las regiones de la retina que influyeron en las predicciones realizadas por cada modelo. De esta manera, fue posible complementar la evaluación cuantitativa con un análisis de interpretabilidad y determinar el efecto real de los mecanismos de atención sobre el desempeño y la capacidad de generalización en escenarios de dominio cruzado.




Figura 2. Arquitectura ResNet50 + CBAM

3.5 Diseño experimental y comparativa de modelos

El diseño experimental implementado corresponde a un esquema multifactorial controlado. A diferencia de enfoques previos que evaluaban un número reducido de combinaciones, este estudio considera de forma sistemática todos los factores relevantes y sus interacciones, generando un total de 54 evaluaciones finales. Para ello se entrenaron 18 modelos distintos ($3 \text{ datasets} \times 2 \text{ arquitecturas} \times 3 \text{ semillas}$), y cada modelo fue evaluado en los tres datasets disponibles, permitiendo tanto la evaluación intra-dominio como la evaluación cruzada entre dominios. Los factores y niveles del diseño se presentan en la Tabla 1 [22], [25].

Tabla 1. Factores y niveles del diseño experimental multifactorial.

Factor	Niveles
Dataset de entrenamiento	APTOS 2019, Messidor, ODIR
Dataset de prueba	APTOS 2019, Messidor, ODIR
Arquitectura	ResNet50 Base, ResNet50 + CBAM
Semilla experimental	42, 123, 2025
Total de evaluaciones	$54 = 3 \times 3 \times 2 \times 3$

Las variables de respuesta del experimento son las métricas de desempeño del modelo: F1 macro (métrica principal), accuracy (métrica secundaria), AUC por dataset de prueba y recall por clase. Se prioriza el F1 macro sobre el accuracy debido al desbalance de clases presente en los datos, ya que el accuracy puede ser artificialmente alto cuando el modelo predice sistemáticamente la clase mayoritaria. Las variables controladas incluyen el tamaño de imagen (224×224 píxeles), la arquitectura backbone (ResNet50 preentrenada en ImageNet) [10], las técnicas de preprocesamiento y aumento de datos descritas en la sección 2.4 [16], y el tamaño de los splits mantenidos iguales para los tres datasets mediante muestreo estratificado. Las variables no controladas incluyen la variabilidad intrínseca entre datasets: tipo de cámara, nivel de iluminación, resolución, criterios de etiquetado y distribución demográfica de los pacientes [22], [25], [28].

Con el fin de garantizar una comparación justa entre datasets con diferente volumen y distribución de clases, se implementó una estrategia de muestreo estratificado controlado. El conjunto de entrenamiento quedó conformado por 1,224 imágenes por dataset (734 de clase 0, 184 de clase 1, 238 de clase 2, 48 de clase 3 y 20 de clase 4), el de validación por 305 imágenes y el de prueba por 205 imágenes, manteniendo proporciones equivalentes de severidad en todos los casos. Para compensar el desbalance interno de clases se aplicaron pesos en la función de pérdida CrossEntropyLoss, asignando mayor penalización a los errores en clases minoritarias: 0.33 para clase 0, 1.33 para clase 1, 1.03 para clase 2, 5.10 para clase 3 y 12.24 para clase 4. El entrenamiento de ambas arquitecturas se realizó con PyTorch utilizando el optimizador Adam, un máximo de 20 épocas y early stopping para evitar sobreajuste [24], [27].

Para la variante ResNet50 + CBAM se implementó una estrategia de entrenamiento en dos fases: una fase de calentamiento (warm-up) en la que se congeló el backbone y se entrenaron únicamente los módulos CBAM y la capa de clasificación, seguida de una fase de fine-tuning con la red completa y tasas de aprendizaje diferenciadas. Todos los experimentos se ejecutaron con tres semillas (42, 123 y 2025) para evaluar la reproducibilidad de los resultados. La evaluación cruzada entre dominios es el componente central de este diseño, ya que permite analizar si los modelos mantienen su rendimiento cuando se aplican a imágenes provenientes de una fuente diferente a la utilizada durante el entrenamiento, condición que se aproxima a los escenarios de despliegue clínico real donde los equipos de captura y las poblaciones de pacientes varían [22], [25], [28]. Asimismo, el uso de múltiples semillas aporta mayor robustez y estabilidad a los resultados obtenidos [22], [23].

3.6 Alcance y limitaciones

Este estudio presenta diversas limitaciones que deben ser consideradas al interpretar los resultados obtenidos. Aunque los experimentos fueron diseñados para evaluar la capacidad de generalización de las arquitecturas estudiadas, existen factores asociados a los datos disponibles y al contexto de aplicación que pueden influir sobre el comportamiento de los modelos. La identificación de estas limitaciones resulta necesaria para contextualizar adecuadamente los hallazgos y definir posibles líneas de investigación futuras [19].

Como primer punto, los experimentos se basan exclusivamente en datasets públicos, los cuales pueden no representar completamente la diversidad de condiciones clínicas, étnicas y demográficas presentes en la práctica médica real [19]. Esto puede influir en la capacidad del modelo para generalizar a poblaciones no representadas en los datos analizados [30]. En segundo lugar, el estudio se centra únicamente en imágenes de fondo de ojo en dos dimensiones, sin incorporar información clínica adicional del paciente, como edad, duración de la diabetes o niveles de glucosa, factores que podrían mejorar el rendimiento del modelo y su utilidad clínica [19].

Asimismo, no se realizó una validación clínica prospectiva ni una comparación directa con el diagnóstico realizado por especialistas en oftalmología, lo que limita la evaluación del modelo como herramienta de apoyo diagnóstico en entornos reales [24]. Finalmente, este trabajo no aborda aspectos relacionados con la interpretabilidad clínica profunda, la integración del sistema en flujos hospitalarios reales ni las consideraciones éticas y regulatorias necesarias para su implementación en entornos médicos. Estas limitaciones deben ser consideradas al extrapolar los resultados obtenidos hacia escenarios de aplicación clínica [24], [30].

En conjunto, los resultados obtenidos deben interpretarse como evidencia experimental sobre la capacidad de generalización de las arquitecturas estudiadas y no como una validación definitiva para su utilización en la práctica médica. Las limitaciones identificadas constituyen oportunidades para futuras investigaciones orientadas a incorporar información clínica complementaria, realizar validaciones prospectivas y avanzar hacia sistemas de inteligencia artificial más robustos, confiables y clínicamente validados [19], [24], [30].

4. Resultados y Discusión

4.1 Desempeño Global por Arquitectura

Una primera aproximación al comportamiento de las arquitecturas evaluadas consiste en analizar las métricas globales promediadas sobre las 54 evaluaciones del diseño factorial. Esta visión agregada permite identificar tendencias generales antes de profundizar en los análisis por dominio y por clase, constituyendo un punto de referencia para interpretar el efecto de la incorporación de los módulos de atención CBAM sobre el desempeño del modelo [34], [35].

La Tabla 2 presenta los resultados obtenidos. El modelo base ResNet50 supera a la variante con CBAM en todas las métricas principales: F1 macro (38.4 % vs 33.5 %), accuracy (52.6 % vs 48.0 %) y AUC (0.75 vs 0.71). De manera particular, el modelo base también presenta mayores valores de recall en las clases severa y proliferativa, las cuales poseen una mayor importancia clínica. Estas diferencias sugieren que, bajo las condiciones evaluadas, la incorporación de CBAM no produjo una mejora global en la capacidad de clasificación.

Tabla 2. Comparativa de métricas globales entre arquitecturas promediadas sobre 54 evaluaciones.

Métrica	ResNet50 Base	ResNet50 + CBAM	Δ
F1 macro (%)	38.4	33.5	−4.9 pp
Accuracy (%)	52.6	48	−4.6 pp
AUC	0.75	0.71	−0.04
Recall Clase 3 – Severa (%)	44.9	36.8	−8.1 pp
Recall Clase 4 – Proliferativa (%)	36.7	32.2	−4.5 pp
Brecha Accuracy vs F1 macro	14.2 pp	14.5 pp	—

La brecha de aproximadamente 14 puntos porcentuales entre accuracy y F1 macro, presente de forma consistente en ambas arquitecturas, confirma la existencia de un sesgo sistemático hacia la clase mayoritaria (Sin DR), la cual representa alrededor del 60 % de los datos de entrenamiento. Este comportamiento coincide con lo reportado en estudios sobre clasificación desbalanceada, donde el accuracy puede sobreestimar el desempeño cuando existe predominio de una clase específica [16], [24], [27]. Por esta razón, el F1 macro constituye una métrica más adecuada para evaluar el comportamiento del modelo en todas las categorías de severidad.

Los resultados globales evidencian que, contrario a la hipótesis inicial, la incorporación de CBAM no produjo una mejora en el desempeño general del modelo bajo las condiciones de este experimento. La consistencia de esta tendencia en F1 macro, accuracy y AUC simultáneamente descarta que el resultado sea consecuencia de una métrica particular y motiva un análisis más detallado por combinación de dominio y por clase de severidad, con el fin de identificar los escenarios específicos en los que cada arquitectura presenta ventajas o limitaciones. Asimismo, estos hallazgos contrastan con investigaciones previas que reportan mejoras mediante mecanismos de atención en tareas de clasificación de imágenes médicas [35], [36], [37].

4.2 Análisis de generalización cruzada

La generalización entre dominios constituye el eje central de este estudio, dado que en la práctica clínica los modelos de diagnóstico automatizado suelen aplicarse a imágenes provenientes de equipos y poblaciones distintas a las utilizadas durante el entrenamiento. Para evaluar esta capacidad, se construyeron matrices de F1 macro que relacionan cada combinación de dataset de entrenamiento con cada dataset de prueba, promediando los resultados sobre las tres semillas experimentales. Este análisis permite distinguir entre el rendimiento intra-dominio, donde el modelo se evalúa en imágenes de la misma fuente con que fue entrenado, y la generalización cruzada real, donde se enfrenta a un dominio nuevo [22], [25].

Las Tablas 3 y 4 presentan las matrices correspondientes al modelo base y a la variante con CBAM, respectivamente. El análisis revela tres patrones consistentes. En primer lugar, ambos modelos presentan su mejor desempeño en la evaluación intra-dominio: el modelo base alcanza un F1 macro de 72.5 % en la combinación Messidor-Messidor y de 53.9 % en APTOS-APTOS, mientras que CBAM obtiene 60.0 % y 59.7 % en las mismas combinaciones. En segundo lugar, el cambio de dominio produce caídas importantes en el rendimiento para ambas arquitecturas. Por ejemplo, la combinación APTOS-ODIR desciende hasta 20.4 % en el modelo base y 15.0 % en CBAM, representando pérdidas superiores a 30 puntos porcentuales respecto a la evaluación propia, comportamiento consistente con lo reportado en estudios sobre cambio de dominio en imágenes médicas [22], [25], [28].

Tabla 3. Matriz de F1 macro (%) del modelo ResNet50 Base.

Entrenamiento ↓ / Prueba →	APTOS	Messidor	ODIR
APTOS	53.90%	27.80%	20.40%
Messidor	28.50%	72.50%	31.80%
ODIR	27.40%	33.50%	50.00%

Tabla 4. Matriz de F1 macro (%) del modelo ResNet50 + CBAM

Entrenamiento ↓ / Prueba →	APTOS	Messidor	ODIR
APTOS	59.70%	16.70%	15.00%
Messidor	22.40%	60.00%	28.90%
ODIR	24.30%	26.70%	48.30%

En tercer lugar, el modelo base supera a CBAM en ocho de las nueve combinaciones posibles. La única excepción corresponde a la evaluación APTOS→APTOS, donde CBAM obtiene un F1 macro de 59.7 % frente al 53.9 % alcanzado por ResNet50 Base, con una diferencia favorable de 5.8 puntos porcentuales. Este comportamiento sugiere que la incorporación del mecanismo de atención proporciona beneficios únicamente cuando el dominio de entrenamiento y evaluación coincide y las características visuales del conjunto de datos presentan una alta homogeneidad [34], [35], [36].

Los resultados de generalización cruzada indican que la ventaja de CBAM está circunscrita al único escenario donde el dominio de entrenamiento y prueba coinciden y provienen del dataset de mayor calidad y consistencia visual del experimento. Fuera de ese contexto, el modelo base muestra una mayor capacidad de transferencia entre dominios. Este hallazgo sugiere que los módulos de atención de CBAM aprenden representaciones dependientes del dominio de entrenamiento en lugar de características retinianas invariantes y transferibles, limitando su utilidad en escenarios de despliegue clínico real donde la fuente de las imágenes varía. Este comportamiento contrasta con trabajos previos que reportan mejoras mediante mecanismos de atención en tareas de clasificación de imágenes médicas [35], [36], [37].

4.3 Análisis por clase: impacto clínico

Si bien las métricas globales y las matrices de generalización ofrecen una visión comparativa entre arquitecturas y dominios, el análisis por clase resulta fundamental desde una perspectiva clínica. En el diagnóstico de retinopatía diabética, no todos los errores tienen el mismo peso: un falso negativo en las clases de mayor severidad puede derivar en pérdida de visión irreversible si el paciente no recibe atención oportuna [4], [7]. Por esta razón, se calculó el recall promedio por clase para ambas arquitecturas sobre todas las combinaciones de entrenamiento, prueba y semilla, con el fin de evaluar qué tan bien detecta cada modelo los distintos niveles de severidad de la enfermedad.

La Tabla 5 presenta los resultados obtenidos. En contra de la hipótesis inicial, CBAM no mejora el recall en ninguna de las cinco clases evaluadas. La mayor caída se observa en las categorías Severa (−8.1 pp) y Moderada (−6.3 pp), precisamente los niveles de mayor relevancia diagnóstica, donde un caso no detectado implica un mayor riesgo de deterioro visual para el paciente [4], [7]. La clase Sin DR presenta la reducción más moderada (−4.3 pp) y también el recall más alto en ambas arquitecturas (76.1 % para ResNet50 Base y 71.8 % para CBAM), comportamiento consistente con el sesgo hacia la clase mayoritaria identificado previamente [16], [24], [27].

Tabla 5. Recall por clase (%) para ResNet50 Base y ResNet50 + CBAM con su implicación clínica asociada

Clase	Descripción	Riesgo clínico	Recall Base	Recall CBAM	Δ
0	Sin DR	Bajo	76.10%	71.80%	−4.3 pp
1	Leve	Bajo	24.00%	22.70%	−1.3 pp
2	Moderada	Medio	28.40%	22.10%	−6.3 pp
3	Severa	Alto	44.90%	36.80%	−8.1 pp
4	Proliferativa	Crítico	36.70%	32.20%	−4.5 pp

Las clases Leve y Proliferativa, aunque poseen un menor volumen de muestras en el conjunto de prueba, también muestran reducciones de −1.3 pp y −4.5 pp respectivamente bajo la arquitectura con CBAM. En conjunto, estos resultados evidencian que la disminución del desempeño no es uniforme entre categorías, sino que afecta con mayor intensidad las clases asociadas a un mayor riesgo clínico. Este comportamiento resulta especialmente relevante, ya que la sensibilidad en las clases más avanzadas de la enfermedad constituye uno de los principales criterios de interés en sistemas de apoyo al diagnóstico [4], [5], [7].

El análisis por clase confirma que la caída de desempeño de CBAM se concentra de manera desproporcionada en las categorías de mayor relevancia clínica. Este resultado tiene implicaciones directas para cualquier escenario de despliegue, ya que un modelo que reduce el recall en las clases Moderada y Severa representa un mayor riesgo para el paciente que uno con menor F1 macro global pero mayor capacidad para detectar casos críticos. Bajo las condiciones experimentales evaluadas, el modelo base ResNet50 presenta una distribución de errores clínicamente más segura que la variante con CBAM, favoreciendo una mayor sensibilidad en las categorías con mayor riesgo de progresión de la enfermedad.

4.4 Estabilidad entre semillas

Para que los resultados de un experimento sean científicamente válidos, es necesario verificar que no sean producto de una inicialización aleatoria particularmente

favorable o desfavorable. En este estudio, el uso de tres semillas experimentales distintas (42, 123 y 2025) permite cuantificar la variabilidad de los resultados y determinar si las diferencias observadas entre arquitecturas son reproducibles o sensibles a la configuración inicial del modelo. Este análisis constituye un elemento importante para evaluar la robustez y confiabilidad de los hallazgos obtenidos [22], [23].

La Tabla 6 presenta la variación del F1 macro entre semillas para cada combinación de dataset y arquitectura. La variación global observada es de 3.9 puntos porcentuales, lo que indica que los resultados son reproducibles en términos generales. Sin embargo, la combinación Messidor + CBAM presenta un comportamiento atípico, con un rango de 10.9 pp y una desviación estándar de 4.4 entre semillas (31.7 %, 42.6 % y 37.1 % para las semillas 42, 123 y 2025 respectivamente), constituyendo la mayor inestabilidad registrada durante el experimento. En contraste, APTOS Base y APTOS CBAM presentan los rangos más bajos (4.7 pp y 4.1 pp), mientras que ODIR Base muestra una variabilidad intermedia atribuible a la mayor heterogeneidad visual del dataset.

Tabla 6. Estabilidad del F1 macro (%) entre semillas experimentales

Combinación	Semilla 42	Semilla 123	Semilla 2025	Media	Std	Rango	Estabilidad
APTOS Base	31.4 %	36.1 %	34.5 %	34.0 %	2.0	4.7 pp	Alta
APTOS CBAM	28.5 %	32.6 %	30.2 %	30.4 %	1.7	4.1 pp	Alta
Messidor Base	40.7 %	46.0 %	46.1 %	44.3 %	2.5	5.4 pp	Alta
Messidor CBAM	31.7 %	42.6 %	37.1 %	37.1 %	4.4	10.9 pp	Baja
ODIR Base	41.3 %	38.5 %	31.0 %	36.9 %	4.3	10.3 pp	Media
ODIR CBAM	34.0 %	35.3 %	30.0 %	33.1 %	2.3	5.3 pp	Alta

La inestabilidad observada en la combinación Messidor + CBAM sugiere que el módulo de atención es especialmente sensible a la inicialización aleatoria cuando el dominio de entrenamiento presenta características visuales que requieren un mayor tiempo de convergencia para los parámetros adicionales incorporados por CBAM [34], [35]. Este comportamiento podría indicar la necesidad de utilizar estrategias de entrenamiento más robustas, como un mayor número de épocas de calentamiento o esquemas de inicialización transferida desde modelos con atención previamente entrenados [36], [37]. Asimismo, la variabilidad observada en ODIR Base es consistente con la heterogeneidad visual propia de este conjunto de datos [3].

En términos metodológicos, la estabilidad general observada en la mayoría de las combinaciones valida que las conclusiones del estudio no dependen de una semilla específica, sino que reflejan tendencias consistentes del comportamiento de las arquitecturas evaluadas. La baja variabilidad registrada en la mayoría de los escenarios aporta mayor confianza a los resultados obtenidos y respalda la reproducibilidad de los experimentos realizados [22], [23].

4.5 Análisis de interpretabilidad – GradCAM

Con el objetivo de complementar el análisis cuantitativo y comprender el razonamiento interno de cada arquitectura, se aplicó la técnica Gradient-weighted Class Activation Mapping (GradCAM) para visualizar las regiones de la imagen que influyen en el proceso de clasificación [38]. Esta herramienta permite evaluar si las decisiones del modelo se basan en estructuras retinianas clínicamente relevantes, como la región macular, los vasos sanguíneos y las lesiones asociadas a la retinopatía diabética, o si responden a patrones visuales no específicos de la enfermedad. De esta manera, el análisis de interpretabilidad aporta evidencia adicional sobre la confiabilidad de los modelos en escenarios clínicos reales [39], [40].

En la Figura 3, correspondiente a una imagen del dataset APTOS evaluada con el modelo base, se observa que la red asigna mayor relevancia a regiones específicas de la retina, principalmente en áreas cercanas a estructuras vasculares y zonas centrales del fondo de ojo. De forma complementaria, la Figura 4 muestra que también existen activaciones en regiones que no corresponden directamente a lesiones identificables, lo que sugiere que parte de la información utilizada por el modelo proviene del contexto general de la imagen. El análisis comparativo entre ResNet50 Base y ResNet50 + CBAM revela diferencias en la distribución espacial de las activaciones según el dominio evaluado, especialmente en los escenarios donde ambas arquitecturas presentan diferencias de desempeño.




Figura 3. Imagen original de retina




Figura 4. Imagen generada por Gradcam

En la evaluación intra-dominio con APTOS, donde CBAM obtiene su única ventaja cuantitativa, los mapas de activación muestran una concentración más pronunciada sobre la región macular y los vasos sanguíneos perimaculares. Sin embargo, esta focalización más precisa no se reproduce de forma consistente en los escenarios de evaluación cruzada, donde ambas arquitecturas presentan activaciones más dispersas y menos alineadas con las estructuras patológicas esperadas. Este comportamiento sugiere que las diferencias observadas en los mapas de atención dependen en gran medida del dominio sobre el cual fue entrenado el modelo [34], [38].

El análisis mediante GradCAM resulta coherente con los resultados cuantitativos presentados en las secciones anteriores. CBAM logra una atención más alineada con las estructuras retinianas en el único escenario donde también obtiene una ventaja en F1 macro, correspondiente a la evaluación intra-dominio con APTOS. No obstante, esta capacidad no se mantiene al enfrentarse a imágenes provenientes de otros datasets. Estos resultados sugieren que la mayor concentración de activaciones observada en CBAM no constituye una propiedad general del mecanismo de atención, sino que refleja la presencia de representaciones específicas del dominio de entrenamiento, limitando su interpretabilidad como evidencia de robustez clínica en escenarios de generalización cruzada [35], [36], [37].

4.6 Discusión

El análisis GradCAM es coherente con los resultados cuantitativos de las secciones anteriores: CBAM logra una atención más clínicamente alineada en el dominio donde también obtiene ventaja en F1 macro (APTOS intra-dominio), pero no mantiene esa focalización al enfrentarse a imágenes de otros datasets. Este hallazgo sugiere que la mayor concentración de activaciones de CBAM en zonas patológicas no es una propiedad general del módulo de atención, sino una consecuencia de haber aprendido representaciones específicas del dominio APTOS durante el entrenamiento, lo cual limita su interpretabilidad como evidencia de robustez clínica en escenarios de dominio cruzado.

La superioridad del modelo base en 8 de 9 combinaciones de evaluación cruzada, junto con su mayor recall en todas las clases de severidad, contrasta con estudios previos que reportan mejoras mediante mecanismos de atención en tareas de clasificación de imágenes médicas [35], [36], [37]. Esta discrepancia puede explicarse por tres factores identificados en el análisis de resultados. En primer lugar, el tamaño del conjunto de entrenamiento (1,224 imágenes por dataset) puede ser insuficiente para que los módulos CBAM aprendan representaciones transferibles entre dominios, dado que la literatura sugiere que los mecanismos de atención son especialmente sensibles al volumen de datos disponible [34], [36]. En segundo lugar, la estrategia de entrenamiento en dos fases puede requerir más épocas de calentamiento para lograr la convergencia adecuada de los parámetros nuevos de CBAM dentro del límite de 20 épocas máximas, hipótesis que se ve

respaldada por la mayor inestabilidad entre semillas observada en la combinación Messidor + CBAM (rango 10.9 pp). En tercer lugar, la única ventaja documentada de CBAM (APTOS-APTOS, +5.8 pp) se observa con el dataset de mayor calidad y consistencia visual del experimento, lo que sugiere que el módulo de atención sí puede aprender representaciones relevantes cuando la distribución de imágenes es más homogénea, pero no logra generalizarlas a dominios con mayor variabilidad en las condiciones de captura. Desde una perspectiva clínica, la caída de CBAM en el recall de las clases Severa (−8.1 pp) y Moderada (−6.3 pp) es el hallazgo de mayor relevancia práctica, dado que estas son las categorías donde un error de clasificación tiene consecuencias más graves para el paciente [4], [7], [8].

Los resultados sugieren que la efectividad de CBAM como mecanismo de mejora de la generalización en imágenes médicas está condicionada por factores como el volumen de datos de entrenamiento, la homogeneidad del dominio y la estrategia de inicialización y calentamiento de sus parámetros. Estos hallazgos tienen implicaciones directas para el diseño de futuros experimentos: la incorporación de módulos de atención en modelos de diagnóstico de retinopatía diabética requiere conjuntos de datos de mayor tamaño, estrategias de fine-tuning progresivo con más épocas de calentamiento, o la exploración de arquitecturas de atención alternativas con menor número de parámetros adicionales que resulten más estables con datos limitados.

4.7 Requerimientos computacionales y perspectivas con modelos Transformer

La reproducibilidad de los experimentos de aprendizaje profundo depende no solo del diseño metodológico implementado, sino también de los recursos computacionales disponibles. Por esta razón, resulta importante documentar la infraestructura utilizada durante el entrenamiento y analizar cómo podrían variar estos requerimientos al considerar arquitecturas más recientes basadas en mecanismos de atención global. Esta información permite dimensionar la factibilidad de replicar los experimentos y establecer posibles líneas de investigación futuras.

Los experimentos fueron ejecutados sobre aproximadamente 5,200 imágenes de retina utilizando una GPU NVIDIA GeForce RTX 5070 Ti con 17.1 GB de memoria VRAM, un procesador AMD Ryzen 7 9800X3D de 8 núcleos físicos y 33.5 GB de memoria RAM. Bajo estas condiciones fue posible completar los experimentos con tiempos promedio de entrenamiento de aproximadamente 3.5 minutos por ejecución para ResNet50 Base y 8.7 minutos para ResNet50 + CBAM (incluyendo sus dos fases de entrenamiento), con un tiempo total aproximado de 1.8 horas para las 18 corridas de entrenamiento. El modelo ResNet50 + CBAM mantuvo un tamaño de ~26.0 millones de parámetros, representando un incremento de ~2.5 millones de parámetros (+10.6%) respecto a la arquitectura base (~23.5M). Los experimentos fueron ejecutados de forma local sin costo monetario asociado.

Para la replicación o extensión de este experimento a mayor escala, se recomienda disponer de una GPU con al menos 16 GB de memoria VRAM, como la NVIDIA Tesla V100 o equivalente, junto con un mínimo de 8 núcleos de procesamiento y 64 GB de memoria RAM. Bajo esa configuración, y con un conjunto de datos de aproximadamente 10,000 imágenes por dataset, se estima un tiempo promedio de entrenamiento de 10 a 15 minutos por ejecución, con un tiempo total aproximado de 3 a 4 horas para las 18 corridas del diseño factorial. En caso de optar por infraestructura en la nube, el costo estimado de ejecución completa oscila entre 150 y 200 dólares considerando recursos de almacenamiento, máquinas virtuales y procesamiento GPU bajo demanda. Adicionalmente, se recomienda que el conjunto de datos utilizado cuente con una distribución más uniforme entre las cinco clases de severidad, incrementando especialmente la representación de las clases Severa y Proliferativa, que en el presente experimento contaron con apenas 48 y 20 imágenes de entrenamiento respectivamente. Una distribución más balanceada reduciría la dependencia del modelo hacia la clase mayoritaria Sin DR, disminuiría la brecha observada entre accuracy y F1 macro, y permitiría evaluar con mayor rigor el comportamiento de ambas arquitecturas en los casos clínicamente más críticos.

En contraste, los modelos Transformer, como Vision Transformer (ViT) y Swin Transformer, sustituyen gran parte de las operaciones convolucionales por mecanismos de autoatención global, permitiendo modelar relaciones entre regiones distantes de la imagen y capturar representaciones más contextuales [41], [42]. De acuerdo con la literatura, esta característica ha permitido obtener resultados competitivos en tareas de clasificación y análisis de imágenes médicas, incluyendo aplicaciones oftalmológicas. En el contexto de la presente investigación, estas arquitecturas podrían contribuir a mejorar la capacidad de generalización entre dominios al aprender características menos dependientes de las particularidades de cada dataset y más asociadas a patrones retinianos compartidos. No obstante, su entrenamiento demandaría una mayor capacidad computacional, incluyendo GPUs con memorias entre 40 y 80 GB de VRAM, tiempos de entrenamiento superiores y conjuntos de datos de mayor tamaño para garantizar una convergencia estable [41], [42].

Bajo las condiciones experimentales consideradas, ResNet50 y ResNet50 + CBAM representan una alternativa computacionalmente eficiente para la clasificación de imágenes de retina. Sin embargo, los avances recientes en arquitecturas Transformer abren nuevas oportunidades para futuras investigaciones orientadas a explorar mecanismos de autoatención global y evaluar su impacto sobre la capacidad de generalización, la interpretabilidad y la robustez en escenarios de dominio cruzado. En este sentido, modelos como Vision Transformer y Swin Transformer constituyen una línea prometedora para extender los resultados obtenidos en este trabajo y avanzar hacia sistemas de diagnóstico más transferibles y clínicamente confiables [41], [42].

5. Conclusiones

El presente estudio evaluó el efecto de incorporar el módulo de atención Convolutional Block Attention Module (CBAM) sobre una arquitectura ResNet50 para la detección y clasificación de retinopatía diabética, mediante un diseño experimental multifactorial que consideró diferentes datasets, arquitecturas y semillas experimentales. La investigación permitió analizar el comportamiento de los modelos tanto en escenarios intra-dominio como en condiciones de generalización cruzada entre fuentes de datos heterogéneas. Asimismo, se complementó la evaluación cuantitativa con análisis de interpretabilidad mediante GradCAM y un estudio de estabilidad entre semillas, con el propósito de obtener una visión más integral del desempeño de las arquitecturas evaluadas.

Los resultados obtenidos no respaldan la hipótesis inicial del estudio. En la mayoría de los escenarios de evaluación cruzada, ResNet50 Base presentó una mayor capacidad de generalización que la variante con CBAM, con la única excepción de la evaluación intra-dominio sobre APTOS. De igual manera, el análisis por clase mostró que las principales caídas de desempeño de CBAM se concentraron en las categorías Moderada y Severa, que poseen una mayor relevancia clínica. Adicionalmente, la brecha observada entre accuracy y F1 macro confirmó la presencia de sesgo hacia la clase mayoritaria, evidenciando la importancia de utilizar métricas más robustas en problemas con distribución desbalanceada. Los análisis de estabilidad e interpretabilidad también mostraron que las ventajas de CBAM dependen en gran medida del dominio de entrenamiento y no se mantienen de forma consistente al enfrentarse a imágenes provenientes de otros conjuntos de datos.

Los hallazgos obtenidos aportan evidencia experimental sobre las condiciones bajo las cuales los mecanismos de atención pueden mejorar o limitar la capacidad de generalización de modelos de aprendizaje profundo aplicados a imágenes médicas. Los resultados demuestran que la incorporación de módulos de atención no garantiza por sí sola una mejora en la robustez y transferibilidad del modelo, y que factores como el tamaño del conjunto de entrenamiento, la homogeneidad del dominio y la estrategia de inicialización desempeñan un papel determinante en su efectividad.

En este sentido, la utilización de conjuntos de datos de mayor escala, estrategias de entrenamiento más robustas y arquitecturas alternativas, incluyendo modelos Transformer, representa una oportunidad para continuar avanzando hacia sistemas de apoyo diagnóstico más confiables, interpretables y clínicamente transferibles.

CONFLICTO DE INTERÉS

Los autores declaran no tener conflicto de intereses.

CONTRIBUCIÓN Y APROBACIÓN DE LOS AUTORES

L. L. y J. B. participaron en el desarrollo experimental y ejecución de los modelos. A. N. estuvo a cargo de la investigación bibliográfica, análisis de resultados, redacción y revisión del manuscrito, con apoyo en las visualizaciones. J. S. contribuyó en el desarrollo de los tableros de visualización y análisis de resultados. R. V. participó en la conceptualización general del estudio.

J. C. realizó la supervisión académica, revisión científica y aprobación final del artículo.

Todos los autores afirmamos que hemos leído y aprobado la versión final de este artículo.

AGRADECIMIENTOS

Los autores agradecen a los responsables de los datasets APTOS 2019 y Messidor por facilitar el acceso a los datos e imágenes médicas utilizadas en esta investigación. La disponibilidad de estos conjuntos de datos permitió el desarrollo de los experimentos y el análisis comparativo necesarios para evaluar la capacidad de generalización de los modelos de redes neuronales convolucionales en la detección de retinopatía diabética.

REFERENCIAS

- [1] Herrero, M. (2019). *APTOS-2019 dataset*. KAGGLE. Recuperado 7 de marzo de 2026, de <https://www.kaggle.com/datasets/mariaherrero/aptos2019/dataset>
- [2] Maffre, G. P. G. G. B. L. J. R. D. E. M. F. A. D. H. (2022, 24 mayo). Messidor-2 - ADCIS. ADCIS. <https://www.adcis.net/en/third-party/messidor2/>
- [3] Li, X., Pang, T., Xiong, B., Liu, W., Liang, P., & Wang, T. (2019). *ODIR-5K: Ocular Disease Intelligent Recognition Dataset* Kaggle. <https://www.kaggle.com/datasets/andrewmvd/ocular-disease-recognition-odir5k>
- [4] Rosas, E. P. (2024). ASOCIACIÓN DE LA CONSULTA OFTALMOLÓGICA EN PACIENTES CON DIABETES MELLITUS TIPO II y RETINOPATÍA DIABÉTICA. Centros, 13(1), 9-23. <https://doi.org/10.48204/j.centros.v13n1.a4631>
- [5] Historia natural de retinopatía diabética en un estudio a largo plazo en pacientes con diabetes tipo 1. Factores de riesgo para progresión a enfermedad proliferante https://www.scielo.cl/scielo.php?script=sci_arttext&pid=S0034-98872009000900002
- [6] Pineda SC, Zarco VXJ, Ruiz MML. Retinopatía diabética, una complicación descuidada. Aten Fam. 2018;25(2):83-85. <https://www.medigraphic.com/cgi-bin/new/resumen.cgi?IDARTICULO=78202>

- [7] Ruiz MM, Escobar YNV, Ramos LM, et al. El impacto social de la retinopatía diabética. *Rev Acta Médica*. 2020;21(4):1-15. <https://www.medigraphic.com/cgi-bin/new/resumen.cgi?IDARTICULO=103853>
- [8] Rodríguez Rodríguez, Beatriz. (2015). Prevención de ceguera por retinopatía diabética: ¿dónde estamos?. *Revista Cubana de Oftalmología*, 28(1) Recuperado en 21 de marzo de 2026, de http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0864-21762015000100013&lng=es&tlng=es
- [9] Meller, G. (2025, 16 enero). Ocular disease recognition using convolutional neural networks. *Towards Data Science*. <https://towardsdatascience.com/ocular-disease-recognition-using-convolutional-neural-networks-c04d63a7a2da/>
- [10] Pratt, H., et al. (2016). CNN for diabetic retinopathy. <https://doi.org/10.1016/j.procs.2016.07.014>
- [11] Martínez Llamas, Javier (2018). *Reconocimiento de imágenes mediante redes neuronales convolucionales*. <https://oa.upm.es/53050/>
- [12] Redes neuronales convolucionales: un modelo de Deep Learning en imágenes diagnósticas. <https://rcr.acronline.org/index.php/rcr/article/view/161/219>
- [13] Subramanian, S. (2023, 16 octubre). *Convolutional Neural Network Model for Diabetic Retinopathy Feature Extraction and Classification*. ARXIV. Recuperado 17 de marzo de 2026, de <https://arxiv.org/html/2310.10806>
- [14] Yamashita, R., Nishio, M., Do, R. K., & Togashi, K. (2018). Convolutional neural networks: an overview and application in radiology. *Insights into Imaging*. <https://doi.org/10.1007/s13244-018-0639-9>
- [15] Pratt, H., Coenen, F., Broadbent, D., Harding, S., & Zheng, Y. (2016). Convolutional Neural Networks for Diabetic Retinopathy. Acceso directo al artículo: <https://www.sciencedirect.com/science/article/pii/S1877050918308019>
- [16] Gulshan, V., et al. (2016). Deep learning for diabetic retinopathy. <https://doi.org/10.1001/jama.2016.17216>
- [17] Chitra, R. C., Anusha Bamini, A. M., Punitha, S., Thompson, S., & Sheshikala, M. (2024). CNN-based Integrated Framework for Enhanced Diabetic Retinopathy Detection. *BENTHAM SCIENCE*, 18(3), https://www.researchgate.net/publication/385027028_CNN-Based_Integrated_Framework_for_Enhanced_Diabetic_Retinopathy_Detection
- [18] Sirisati, R. S., Navyasri, V., Swathi, T., Akhila, M., & Astried, A. (2025). Diabetic Retinopathy Prediction Using Deep Learning: Insights From CNN. *International Journal of Advances in Artificial Intelligence and Machine Learning*, 2(3), 178–186. <https://doi.org/10.58723/ijaaiml.v2i3.420>
- [19] Ting, D. S. W., Cheung, C. Y., Lim, G., Tan, G. S. W., Quang, N. D., Gan, A., Hamzah, H., Garcia-Franco, R., Yeo, I. Y. S., Lee, S. Y., Wong, E. Y. M., Sabanayagam, C., Baskaran, M., Ibrahim, F., Tan, N. C., Finkelstein, E. A., Lamoureux, E. L., Wong, I. Y., Bressler, N. M., ... Wong, T. Y. (2017). Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes. *JAMA*, 318(22), 2211–2223. <https://doi.org/10.1001/jama.2017.18152>
- [20] Huang, X., Wang, H., She, C., Feng, J., Liu, X., Hu, X., Chen, L., & Tao, Y. (2022). Artificial intelligence promotes the diagnosis and screening of diabetic retinopathy. *Frontiers in Endocrinology*, 13, 946915. <https://doi.org/10.3389/fendo.2022.946915>
- [21] Dai, L., Sheng, B., Chen, T., Wu, Q., Liu, R., Cai, C., Wu, L., Yang, D., Hamzah, H., Liu, Y., Wang, X., Guan, Z., Yu, S., Li, T., Tang, Z., Ran, A., Che, H., Chen, H., Zheng, Y., ... Jia, W. (2024). Deep learning system for predicting time to progression of diabetic retinopathy. *Nature Medicine*. <https://doi.org/10.1038/s41591-023-02702-z>
- [22] Nadeem, M. W., Goh, H. G., Hussain, M., Liew, S. Y., Andonovic, I., & Khan, M. A. (2022). Deep learning for diabetic retinopathy analysis: A review, research challenges, and future directions. *Sensors*, 22(18), 6780. <https://doi.org/10.3390/s22186780>
- [23] Tsiknakis, N., Theodoropoulos, D., Manikis, G., Ktistakis, E., Boutsora, O., Berto, A., Scarpa, F., Scarpa, A., Fotiadis, D. I., & Marias, K. (2021). Deep learning for diabetic retinopathy detection and classification based on fundus images: A review. *Computers in Biology and Medicine*, 135, 104599. <https://doi.org/10.1016/j.compbiomed.2021.104599>
- [24] Thanikachalam, V., Kabilan, K., & Erramchetty, S. K. (2024). Optimized deep CNN for detection and classification of diabetic retinopathy and diabetic macular edema. *BMC Medical Imaging*, 24(1), 227. <https://doi.org/10.1186/s12880-024-01406-1>
- [25] Single Domain Generalization in Diabetic Retinopathy: A Neuro-Symbolic Learning Approach. <https://arxiv.org/html/2509.02918>
- [26] Sengupta, S., Singh, A., et al. (2020). Cross-domain diabetic retinopathy detection using deep learning. *Semantic Scholar*. <https://www.semanticscholar.org/paper/Cross-domain-diabetic-retinopathy-detection-using-Sengupta-Singh/67c069ee0f944867ca90d7484fd46a65d7d8e64b>

- [27] Akhtar, S., et al. (2025). A deep learning based model for diabetic retinopathy grading using multiple datasets. Scientific Reports. Acceso directo: <https://www.nature.com/articles/s41598-025-87171-9>
- [28] Rahman, A., et al. (2024). Diabetic Retinopathy Detection: A Hybrid Intelligent Deep Learning Model with Cross-Dataset Evaluation. Acceso directo: <https://www.sciopen.com/article/10.32604/cmc.2024.055106>
- [29] Yang, Q., et al. (2025). OcuMDNet: A lightweight CNN for robust multi-disease retinal classification with cross-dataset generalization. Acceso directo: <https://www.sciencedirect.com/science/article/abs/pii/S0014483525004142>
- [30] Santos, M. S., Valadao, C. T., Resende, C. Z., & Cavalieri, D. C. (2024). Predicting diabetic retinopathy stage using Siamese convolutional neural network. Computer Methods in Biomechanics and Biomedical Engineering: Imaging & Visualization, 12(1), Article 2297017. <https://doi.org/10.1080/21681163.2023.2297017>
- [31] A. A. Alkhouly, A. Mohammed and H. A. Hefny, "Improving the Performance of Deep Neural Networks Using Two Proposed Activation Functions," in IEEE Access, vol. 9, pp. 82249-82271, 2021. doi: 10.1109/ACCESS.2021.3085855
- [32] He L, Luan L and Hu D (2025) Deep learning-based image classification for AI-assisted integration of pathology and radiology in medical imaging. Front. Med. 12:1574514. doi: 10.3389/fmed.2025.1574514
- [33] Litjens, G., et al. (2017). A survey on deep learning in medical image analysis. IEEE Transactions on Medical Imaging. 10.1016/j.media.2017.07.005
- [34] S. Woo, J. Park, J.-Y. Lee y I. S. Kweon, "CBAM: Convolutional Block Attention Module," en *Proceedings of the European Conference on Computer Vision (ECCV)*, Munich, Germany, pp. 3–19, 2018. [Online]. Available: <https://arxiv.org/abs/1807.06521>
- [35] M. M. Farag, M. Fouad y A. T. Abdel-Hamid, "Automatic Severity Classification of Diabetic Retinopathy Based on DenseNet and Convolutional Block Attention Module," *IEEE Access*, vol. 10, pp. 38299–38308, 2022, doi: 10.1109/ACCESS.2022.3165193. [Online]. Available: https://www.researchgate.net/publication/359786655_Automatic_Severity_Classification_Of_Diabetic_Retinopathy_Based_On_DenseNet_And_Convolutional_Block_Attention_Module
- [36] T. B. Ovi, M. A. Hossain, M. A. Rahman y M. M. Islam, "Soft-CBAMNet: Soft Convolutional Block Attention Module-Based Network for Diabetic Retinopathy Severity Detection," *International Journal of Imaging Systems and Technology*, vol. 34, no. 4, 2024. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1002/ima.23175>
- [37] J. Cao, J. Chen, X. Zhang y Y. Peng, "Diabetic Retinopathy Classification Based on Dense Connectivity and Asymmetric Convolutional Neural Network," *Neural Computing and Applications*, vol. 37, no. 11, pp. 7527–7540, 2022, doi: 10.1007/s00521-022-07952-5. [Online]. Available: https://www.researchgate.net/publication/365156248_Diabetic_retinopathy_classification_based_on_dense_connectivity_and_asymmetric_convolutional_neural_network
- [38] The Deep Hub, "Convolutional Block Attention Module (CBAM) Overview," Medium, 2023. [Online]. Available: <https://medium.com/thedeephub/convolutional-block-attention-module-cbam-overview-118e14048980>
- [39] A. Hernández, J. Martínez y M. López, "Aplicación de módulo de atención en bloques para clasificación de imágenes médicas," *Memorias CIMCIA*, Universidad Nacional Autónoma de México, 2025. [Online]. Available: <https://virtual.cuautitlan.unam.mx/intar/memoriascimcia/wp-content/uploads/sites/20/2025/12/182-Aplicacion-de-modulo-de-atencion-en-bloques.pdf>
- [40] J. A. Rodríguez, "Implementación de mecanismos de atención convolucional para la mejora de modelos de clasificación de imágenes médicas," Tesis de Maestría, Universidad de los Andes, Colombia, 2024. [Online]. Available: <https://repositorio.uniandes.edu.co/entities/publication/97082e7b-0b63-40e4-a464-639f11cb604c>
- [41] A. Dosovitskiy, L. Beyer, A. Kolesnikov *et al.*, "An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale," *International Conference on Learning Representations (ICLR)*, 2021.
- [42] Z. Liu, Y. Lin, Y. Cao *et al.*, "Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows," *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 10012-10022, 2021.